

PROYECTO INTEGRADOR



PROFESOR: MUBARQUI FERNANDO

ALUMNOS: LOMBARDI SARA

CONTEXTO Y OBJETIVO

Este proyecto analiza el comportamiento de usuarios de una plataforma de streaming de América Latina. El objetivo es aplicar un proceso completo de

inspección, limpieza, análisis exploratorio y reducción de dimensionalidad sobre el dataset provisto por la cátedra, con decisiones justificadas y resultados comunicables.

DATASET Y CALIDAD INICIAL

El dataset contiene 8.160 registros y 8 variables: user_id, age, subscription_plan, monthly_watch_time_mins, country, favorite_genre, last_login_date y customer_support_tickets.

Se detectaron 126 duplicados, 753 valores nulos, inconsistencias en variables categóricas (hasta 26 variantes por variable), valores imposibles en age y customer_support_tickets, y fechas mal formateadas.

DECISIONES DE LIMPIEZA Y PREPARACIÓN

- Eliminación de 126 filas duplicadas
- Normalización de subscription_plan, country y favorite_genre
- Eliminación de registros con edad negativa o mayor a 100
- Eliminación de valores negativos y outlier extremo en watch time
- Imputación de nulos en monthly_watch_time_mins con la mediana (760.8 min)
- Eliminación de fechas inválidas en last_login_date
- Eliminación de tickets negativos y outliers mayores a 10

Retención final: 5.886 registros (72.1% del total original).

Registro completo en: logs/pipeline_log.csv

HALLAZGOS DEL ANÁLISIS EXPLORATORIO

La distribución de edades se concentra entre 20 y 50 años. El tiempo de

visualización presenta distribución aproximadamente simétrica (400-1200 min). No se observaron diferencias marcadas en el tiempo de visualización según el plan de suscripción. El promedio de tickets varía entre países. Las variables numéricas no presentan correlaciones fuertes entre sí.

PCA

Se aplicó estandarización Z-score sobre age, monthly_watch_time_mins y customer_support_tickets antes del PCA. La varianza se distribuyó de forma uniforme: PC1 33.7%, PC2 33.2%, PC3 33.0%, confirmando que las tres variables aportan información independiente y no redundante.

CONCLUSIONES Y LIMITACIONES

El plan de suscripción no determina el tiempo de visualización. La edad no presenta relación lineal con el consumo. Los tickets no reducen significativamente el tiempo de uso. Las conclusiones están condicionadas por la calidad inicial del dataset y la eliminación del 27.9% de registros.

ENLACES

Repositorio: https://github.com/saracarolinalombardi-coder/PI_Mineria_Datos_1

Aplicación: [tu link de Streamlit]